

Analiza porównawcza generatorów liczb pseudolosowych w estymacji wartości π za pomocą algorytmu Monte Carlo

Akademia Górniczo-Hutnicza im. Stanisława Staszica w Krakowie

Wydział Geologii, Geofizyki i Ochrony Środowiska

Inteligencja obliczeniowa w analizie danych

Opracowanie: Kajetan Kowalski¹

Streszczenie: W niniejszej pracy przeanalizowano zastosowanie metody Monte Carlo do estymacji wartości liczby π w oparciu o geometryczny model prawdopodobieństwa. Symulacje przeprowadzono w 10 niezależnych seriach dla prób o liczebności do $N = 10^6$, co umożliwiło ocenę zbieżności estymacji oraz stabilności wyników. Dodatkowo porównano pięć generatorów liczb pseudolosowych różniących się konstrukcją matematyczną i złożonością obliczeniową. Uzyskane wyniki potwierdziły systematyczne zmniejszanie się błędu wraz ze wzrostem liczby prób oraz wykazały, że jakość generatora może wpływać na stabilność estymacji i tempo jej zbieżności.

DEFINICJE GENERATORÓW LICZB PSEUDOLOSOWYCH

Metoda Monte Carlo jako algorytm probabilistyczny swoją dokładność oraz działanie opiera na liczbach losowych, problemem jednak staje się sposób ich pozyskania. Proponowanym rozwiązaniem jest symulowanie ciągów liczb pseudolosowych, czego można dokonywać z różnym rezultatem za pomocą rozmaitych algorytmów. W ramach projektu estymacji wartości liczby π poddano analizie także wpływ obranych generatorów, różniących się konstrukcją matematyczną, na jakość, dokładność, stabilność oraz tempo zbieżności błędu.

Generatory które zosły wykorzystane w badaniu zostały oparte o treść wykładu: Prof. dr hab. inż. Norbert Skoczylas (2026):

- **Biblioteczny (NumPy):** bazuje na funkcji wbudowanej w standardową bibliotekę języka programowania Python. Korzysta ona z algorytmu **Mersenne Twister**, czyli w deterministyczny sposób na podstawie ustalonego ziarna wyznacza kolejne wartości pseudolosowe. Algorytm ten opiera się na generowaniu kolejnych "losowych" wartości na podstawie wewnętrztrznego stanu generatora, a nie na podstawie wzoru rekurencyjnego. Końcowy wynik poddawany jest dodatkowo modyfikacjom bitowym. Jest to standard charakteryzujący się ogromnym okresem ($2^{19937} - 1$) oraz doskonałymi właściwościami statystycznymi w wysokich wymiarach.
- **Liniowy o maksymalnym okresie:** Generator zwracający ciągi liczb na podstawie liniowej rekurencji modulo. Jest odmianą liniowych generatorów dających większą okresowość, wpływając na poprawienie się własności statystycznych, generator jednak pomimo swojej wydajności, jest podatny na korelacje wewnątrzwyrazowe.

$$X_n = (aX_{n-1} + c) \pmod{M}$$

gdzie a to mnożnik, c to przyrost, a M to moduł.

¹kajetankow@student.agh.edu.pl, Nr indeksu: 421071, Kierunek Inżynieria i Analiza Danych, Etap studiów: 3 Rok, VI Semestr, Grupa ćwiczeniowa: 1

- **Generator Afiniczny:** Rozszerzenie metody liniowej, posiada on zabezpieczenie w postaci parametru b , który zapobiega wczesnemu zapętłaniu się ciągu.

$$X_{n+1} = (aX_n + b) \pmod{m}$$

gdzie $0 < a, b < M$ oraz a to mnożnik, b to przesuniecie, a m to moduł.

- **Generator Wielomianowy:** Ma na celu odejście od prostych lub lekko modyfikowanych zależności liniowych. Dzięki zastosowaniu postaci wielomianowej, przewidywalność generatora spada oraz uzyskujemy bardziej złożony sposób wyznaczania kolejnych wartości. Skutkiem tego jest ograniczenie regularności ciągu i zmniejszenie korelacji między kolejnymi elementami składowymi.

$$X_{n+1} = \sum_{i=1}^k a_i X_n^i \pmod{M}$$

gdzie a to tablica współczynników wielomianu, a M to moduł.

- **Generator Inwersyjny:** Metoda nieliniowa wykorzystująca operację odwracania elementu w ciele skończonym. Pojawiły się po to aby wsteczne odtworzenie algorytmu na podstawie ciągu wyjściowego było znacznie utrudnione. Stosowane są takie przekształcenia, które generują ciąg niecechujący się lokalną liniowością.

$$X_{n+1} = \begin{cases} (aX_n^{-1} + b) \pmod{M} & \text{dla } X_n > 0 \\ b \pmod{M} & \text{dla } X_n = 0 \end{cases}$$

gdzie X_n^{-1} oznacza inwersję modularną elementu X_n , zdefiniowaną jako taką liczbę c , która spełnia warunek:

$$(c \cdot X_n) \pmod{M} = 1$$

METODA MONTE CARLO I WYPROWADZENIE WZORU

Przechodząc do głównego zagadnienia badania - metody Monte Carlo, należy wprowadzić czym jest owa metoda. Jest to szeroka klasa algorytmów stochastycznych, które wykorzystywane są do uzyskiwania przybliżonych wyników numerycznych w oparciu o powtarzalne próbkowanie losowe. W niniejszej pracy zostało przedstawione zastosowanie metody Monte Carlo do estymacji wartości liczby π .

1. Istota metody Monte Carlo

Intuicja stojąca za ogólną zasadą Monte Carlo wynika z bezpośredniej analogii między miarą prawdopodobieństwa a klasyczną miarą Lebesgue'a, uogólniającą pojęcia długości, pola powierzchni czy objętości (Wlaz (2025)). Szczególnie dobrze widoczne jest to w zagadnieniach opartych na prawdopodobieństwie geometrycznym, gdzie zdarzenia elementarne odpowiadają punktom z mierzalnego zbioru, a prawdopodobieństwo trafienia w dany podzbiór jest wprost proporcjonalne do jego miary. Metoda Monte Carlo odwraca tę zależność, czyli pozwala szacować nieznaną miarę na podstawie eksperymentalnej oceny prawdopodobieństwa przynależności do zadanego zbioru. Realizuje się to poprzez wielokrotne, jednostajne losowanie punktów i obliczanie odsetku trafień.

Poprawność takiego szacowania można uzasadnić na kilka sposobów. W ujęciu statystycznym, zliczanie trafień (np. w obszar koła) sprowadza się do zliczania sukcesów w schemacie Bernoulliego, gdzie zgodnym estymatorem prawdopodobieństwa jest po prostu stosunek liczby sukcesów do całkowitej liczby prób. Gwarancję poprawności tego estymatora dają Prawa Wielkich Liczb (w tym prawo Bernoulliego oraz mocne prawo wielkich liczb), z których wprost wynika, że przy rosnącej liczbie prób wynik dąży do rzeczywistego prawdopodobieństwa.

2. Geometryczne wyprowadzenie wzoru na π i logika algorytmu

Proces wyznaczania liczby π w zrealizowanym programie opiera się na prostym modelu geometrycznym. Rozpatrujemy kwadrat jednostkowy na płaszczyźnie kartezjańskiej, którego boki mają długość $a = 1$ (obszar określony jako $x \in [0, 1]$ oraz $y \in [0, 1]$). W kwadrat ten wpisana jest ćwiartka koła o promieniu $R = 1$, o środku w początku układu współrzędnych $(0, 0)$.

Zależności pól powierzchni tych figur prezentują się następująco:

- Pole kwadratu: $P_k = a^2 = 1 \cdot 1 = 1$
- Pole ćwiartki koła: $P_c = \frac{1}{4}\pi R^2 = \frac{1}{4}\pi \cdot 1^2 = \frac{\pi}{4}$

Stosunek pola ćwiartki koła do pola kwadratu wynosi zatem dokładnie $\frac{\pi}{4}$.

Zgodnie z zaimplementowanym algorytmem, program generuje pary punktów (x_i, y_i) dla każdego z badanych generatorów. Następnie, dla każdego punktu sprawdzany jest warunek przynależności do wnętrza ćwiartki koła, wynikający bezpośrednio z równania okręgu:

$$x_i^2 + y_i^2 \leq 1$$

Z geometrycznego prawdopodobieństwa wynika, że stosunek liczby punktów trafiających w obszar koła (K) do całkowitej liczby wylosowanych punktów (N) będzie dążył do stosunku ich pól powierzchni, gdy $N \rightarrow \infty$:

$$\frac{K}{N} \approx \frac{P_c}{P_k} = \frac{\pi}{4}$$

Przekształcając to równanie, otrzymujemy wzór operacyjny użyty w symulacji do estymacji wartości π :

$$\pi \approx 4 \cdot \frac{K}{N}$$

W celu przeprowadzenia zaawansowanej analizy zbieżności i błędów, program nie ogranicza się do pojedynczego obliczenia. Skumulowana suma trafień w kolejnych krokach jest na bieżąco dzielona przez rosnącą wartość N , co pozwala na wykreślenie ścieżek zbieżności i badanie stabilności generatorów na przestrzeni wielu niezależnych serii pomiarowych.

ANALIZA WYNIKÓW ESTYMACJI LICZBY π

Niniejsza sekcja skupia się weryfikacji omówionych we wcześniejszym rozdziale założeń teoretycznych metody Monte carlo oraz na analizie wyników estymacji liczby π , pod kątem porównania generatorów, dokładności wyników czy liczebności wymaganych próbek. W tym celu przeprowadzono serię 10 symulacji dla każdego z pięciu badanych algorytmów generujących ciągi liczb pseudolosowych.

Aby wyniki były reprezentatywne i wiarygodne statystycznie, w celu uniezależnienia od przypadkowego jednego ziarna losowego, które mogłoby determinować "przypadkowe" lepsze działanie algorytmu, bądź jego pogorszenie, całe badanie jest powtarzane dziesięciokrotnie. Maksymalna liczba losowań punktów w pojedynczym przebiegu osiągnęła wartość $= 10^6$, co w przypadku koła jednostkowego na wizualizacjach obrazuje niemalże pełne wypełnienie. Wylosowane punkty zostały wykorzystane do estymacji wartości liczby π , która za pomocą zestawu wizualizacji została poddana ocenie.

1. Wpływ liczby prób na dokładność estymacji

Pierwszym krokiem oceny jest zestawienie wyników estymacji stałej π w Tabeli 1. Zestawienie prezentuje jaką dokładność osiągnął dany algorytm oraz jakim błędem w zależności od N jest obciążona estymacja. Aby uniknąć przypadkowych wyników wraz z pierwszym losowaniem w tabeli została przedstawiona wartość uśredniona z 10 niezależnych przebiegów.

Po zagłębieniu się w dane można jednoznacznie potwierdzić stosowność Prawa Wielkich Liczb - globalnie powtarzalne jest polepszanie się dokładności estymacji, a co za tym idzie zmniejszenie się błędów wraz ze wzrostem N (wyjątkiem omówionym w dalszej części jest generator wielomianowy). Dla generatorów wysokiej jakości (np. *NumPy*) osiągana jest precyzja rzędu 10^{-4} dla miliona prób, ale nie wszystkie algorytmy radzą sobie tak dobrze, bowiem zauważalna jest słabość metody wielomianowej, gdzie błąd dla miliona prób w pierwszej serii był większy o około 0.00556 niż przy, teoretycznie słabszych, 10 tysiącach losowań. Wskazuje to na ograniczenia tego generatora takie jak szybkie wyczerpywanie się okresu tego generatora prowadzącego do powstawania skupisk punktów. Wyniki generowanego ciągu pseudolosowego są determinowane przez parametry generatora, w szczególności współczynniki wielomianu oraz warunki początkowe. Zmiana tych parametrów może wpłynąć na długość okresu oraz własności statystyczne ciągu, co potencjalnie pozwala uzyskać lepszą jakość generowanych liczb pseudolosowych. Warta zanotowania jest tożsamość wynikó algorytmu liniowego (LCG) oraz Afinicznego.

Tabela 1. Zestawienie estymat π oraz błędu bezwzględnego w zależności od liczby losowań N .


Generator	N losowań	π (Seria 1)	Błąd (Seria 1)	Średnie π (10 serii)	Średni Błąd
NumPy (<i>lib</i>)	100	3.200000	0.058407	3.088000	0.053593
	1 000	3.112000	0.029593	3.133600	0.007993
	10 000	3.141600	0.000007	3.142200	0.000607
	1 000 000	3.141380	0.000213	3.140957	0.000635
Inwersyjny	100	2.960000	0.181593	3.144000	0.002407
	1 000	3.148000	0.006407	3.164800	0.023207
	10 000	3.129600	0.011993	3.140280	0.001313
	1 000 000	3.144916	0.003323	3.141073	0.000519
Liniowy (LCG)	100	3.160000	0.018407	3.224000	0.082407
	1 000	3.216000	0.074407	3.178800	0.037207
	10 000	3.152800	0.011207	3.142120	0.000527
	1 000 000	3.145052	0.003459	3.141784	0.000191
Afiniczny	100	3.160000	0.018407	3.224000	0.082407
	1 000	3.216000	0.074407	3.178800	0.037207
	10 000	3.152800	0.011207	3.142120	0.000527
	1 000 000	3.145052	0.003459	3.141784	0.000191
Wielomianowy	100	3.160000	0.018407	3.148000	0.006407
	1 000	3.112000	0.029593	3.143200	0.001607
	10 000	3.140000	0.001593	3.144080	0.002487
	1 000 000	3.148748	0.007155	3.140234	0.001359

2. Wizualizacja rozkładu wylosowanych punktów

Po zapoznaniu się ze specyfiką surowych danych i wyników estymacji, warto zastanowić się skąd się te wyniki wywodzą. Pierwszym etapem analizy jakościowej badanych generatorów będzie wizualna ocena równomierności pokrycia przestrzeni próbkowania. W tym celu wygenerowana została figura z wykresami punktowymi, reprezentujących losowe strzały par współrzędnych (x_i, y_i) na płaszczyznę kwadratu jednostkowego.

Wizualizacja została zrealizowana przy użyciu biblioteki *Matplotlib*. Zaimplementowany algorytm iteruje po badanych generatorach oraz progach liczebności ($N \in \{100, 1000, 10000, 1000000\}$). Warto zaznaczyć, że punkty mają zmienną wielkość w zależności od N w celu polepszenia czytelności (wraz ze wzrostem N rozmiar punktu się zmniejsza). Punkty spełniające warunek przynależności do okręgu ($x_i^2 + y_i^2 \leq 1$) zaznaczono kolorem fioletowym, natomiast punkty spudłowane - kolorem limonkowym. Widoczna czarna linia reprezentuje granicę okręgu jednostkowego.

Wizualizacja rozkładu N losowych punktów dla różnych generatorów



Rysunek 1. Macierz rozkładu punktów w zależności od użytego generatora (kolumny) oraz liczby losowań N (rzędy). Wewnątrz wykresów przedstawiona jest aktualna estymata liczby π dla danej serii.

Wnioski z analizy wizualnej:


Na podstawie wygenerowanej macierzy wykresów (Rysunek 1) można sformułować następujące obserwacje:

- Dla $N = 100$ i $N = 1000$ wszystkie generatory wydają się pokrywać płaszczyznę w miarę równomiernie, co pozwala na sformułowanie wstępnych estymat liczby π (oscylujących wokół wartości $2.9 - 3.2$).
- Najciekawszym zjawiskiem zaobserwowanym na wykresie jest zachowanie generatora wielomianowego dla $N = 10^6$. W przeciwieństwie do pozostałych metod, które przy milionie prób tworzą niemal jednolite, wypełnione pola, wykres dla metody wielomianowej wykazuje wyraźną strukturę ziarnistą z widocznymi pustymi przestrzeniami. Jest to objaw krótkiego okresu i zapętlenia się algorytmu - punkty po pewnym czasie zaczynają trafiać dokładnie w te same miejsca, nie wnosząc nowych informacji do estymaty, a jedynie tworząc klastry.
- Zarówno generator biblioteczny, jak i proste generatory LCG oraz aficzne, dla $N = 10^6$ generują estymatę bardzo bliską rzeczywistej wartości π (odchylenie na poziomie trzeciego miejsca po przecinku). Ich rozkład jest optycznie jednolity, co świadczy o ich dobrej przydatności do podstawowych symulacji Monte Carlo.

3. Analiza zbieżności estymaty w dziedzinie liczby prób

Kolejnym aspektem oceny metody Monte Carlo jest badanie dynamiki zbieżności estymaty do rzeczywistej wartości π . Zgodnie z wnioskami wyciągniętymi z wcześniejszych kroków spodziewany jest spadek różnic i stabilizacja wokół wartości oczekiwanej.

W niniejszym podrozdziale analizie poddano przebieg tego procesu. Aby ukazać pełne spektrum zjawiska, od wysoce niestabilnych początków dla nie wielkich próbek po asymptotyczną precyzję dla dużego N , na wykresie 2 zastosowano skalę logarytmiczną. W pierwszej kolejności zaprezentowano ścieżki zbieżności dla pojedynczego, reprezentatywnego przebiegu (Seria 1). W dalszej części przedstawiona zostanie analogiczna analiza dla wyników h z 10 niezależnych serii, co pozwoli wyeliminować szum stochastyczny pojedynczego eksperymentu.



Rysunek 2. Ścieżki zbieżności estymacji liczby π dla pojedynczej serii pomiarowej


Interpretacja wyników dla pojedynczej serii:

Analiza wykresu (Rysunek 2) prowadzi do następujących wniosków:

- W początkowej fazie symulacji ($N < 10^2$) estymaty charakteryzują się potężnymi oscylacjami, osiągając wartości skrajnie odstające od oczekiwanej wartości π .
- Wraz ze wzrostem N (szczególnie po przekroczeniu progu 10^3), amplituda wahań gwałtownie maleje. Ścieżki wszystkich generatorów zaczynają formować charakterystyczny lejek, oscylując coraz ciaśniej wokół czarnej, przerywanej linii reprezentującej teoretyczną wartość π .
- Przy zbliżaniu się do granicy $N = 10^6$, wariancja wizualnie zanika, a wszystkie generatory prezentują wynik bardzo zbliżony do oczekiwanego. Warto zaznaczyć że jest to analiza wizualna i do weryfikacji ewentualnych mikroskopijnych odchyleń, należy odwołać się do wartości numerycznych z tabeli 1.

W celu zminimalizowania wpływu losowej wariancji pojedynczej realizacji oraz sprawdzenia, czy obserwowany proces stabilizacji ma charakter systematyczny, analizę rozszerzono na 10 niezależnych serii symulacyjnych. Każda seria została zainicjowana odmiennym ziarnem generatora liczb pseudolosowych, co pozwoliło uzyskać statystycznie niezależne realizacje procesu i dokonać oceny stabilności oraz wiarygodności wyników.

Analiza stabilności i zbieżności generatorów dla 10 niezależnych serii danych



Rysunek 3. Analiza stabilności i zbieżności estymaty liczby π dla 10 niezależnych przebiegów. Każdy z wykresów prezentuje nałożone na siebie ścieżki (różne kolory) dla danego generatora.


Interpretacja wyników uśrednionych (10 serii):

Zestawienie przebiegów na macierzy wykresów (Rysunek 3) pozwala na sformułowanie głębszych wniosków o naturze badanych generatorów:

- Niezależnie od wybranego ziarna, wszystkie wygenerowane ścieżki bez wyjątku formują lejek i asymptotycznie dążą do wartości π co dowodzi stabilności zaimplementowanej metody Monte Carlo.
- Wykresy pokazują, że do poprawnego wnioskowania wymagana jest większa liczba punktów ponieważ wnioskowanie przy małej liczbie prób ($N < 10^2$), może być niedokładne i mylące.
- Zestawienie macierzowe pozwala wizualnie potwierdzić identyczność działania generatora liniowego kongruencyjnego oraz generatora afinicznego dla przyjętych parametrów startowych. Struktura splotu wszystkich 10 ścieżek jest na obu wykresach wizualnie nieodróżnialna. Wynika to z faktu, że metoda afiniczna jest uogólnieniem metody liniowej, a przy braku silnego, nieliniowego przesunięcia, oba algorytmy generują tożsame cykle.
- Przy osiągnięciu wartości $N \in [10^5, 10^6]$, wiązka ścieżek dla wszystkich 10 seedów staje się bardzo skupiona, co pokazuje, że wpływ początkowego stanu generatora zostaje praktycznie całkowicie wygaszony.

4. Analiza zbieżności błędu bezwzględnego

Kolejnym testem weryfikującym jakość badanych generatorów jest analiza błędu bezwzględnego estymacji $\Delta\pi = |\pi_{est} - \pi|$ w funkcji rosnącej liczby prób N . Zgodnie z probabilistyczną naturą metody Monte Carlo, oczekiwany błąd estymacji powinien maleć proporcjonalnie do odwrotności pierwiastka z liczby prób.




Rysunek 4. Błąd bezwzględny estymacji dla 10 niezależnych serii.

Wnioski z analizy błędu:

- Dla generatora wbudowanego (*NumPy*), inwersyjnego, a także liniowego i afinicznego, wygenerowane ścieżki błędów po początkowych fluktuacjach wyraźnie układają się wzdłuż teoretycznej asymptoty $1/\sqrt{N}$. Potwierdza to ich zadowalające właściwości statystyczne w badanym zakresie $N \leq 10^6$.
- W przypadku generatora wielomianowego można zauważyć nieoczekiwane i nie występujące w przypadku innych generatorów odchylenie wartości. Ta wizualizacja jest twardym dowodem na niską jakość tej implementacji tego algorytmu generatora. W okolicach $N = 10^4$ błąd przestaje maleć, odrywa się od teoretycznego trendu. Oznacza to, że algorytm uległ zapętleniu - powtarza w kółko te same, sekwencje punktów, w związku z czym zwiększanie liczby losowań nie przynosi żadnej poprawy dokładności wyniku.

5. Rozrzut statystyczny i analiza wariancji

Dopełnieniem analizy zbieżności jest ocena rozrzutu statystycznego wyników estymacji dla różnych progów liczby prób N . W tym celu posłużono się wykresami typu boxplot, które wygenerowano na podstawie danych z 10 niezależnych serii. Czerwoną przerywaną linią zaznaczono dokładną wartość stałej π .



Rysunek 5. Wykresy pudełkowe rozrzutu estymacji liczby π dla wybranych progów liczby losowań N .


Wnioski ze zintegrowanej analizy rozrzutu i błędu:

Zestawienie wykresów pudełkowych (Rysunek 5) z wcześniejszą analizą zbieżności błędu pozwala na wyciągnięcie następujących, kluczowych konkluzji:

- Dla poprawnych strukturalnie generatorów (*lib*, *linear*, *affine*, *inv*) obserwuje się drastyczne zmniejszanie się wysokości pudełek wraz ze wzrostem N . Dla prób rzędu $N \in [10^5, 10^6]$ wariancja między dziesięcioma seriami staje się marginalna, a mediany idealnie pokrywają się z teoretyczną wartością π stabilizując się.
- Wykres pudełkowy dla generatora wielomianowego (*poly*) dostarcza ostatecznego uzasadnienia dla zbyt wczesnego zapętlenia się algorytmu. O ile dla małych N rozrzut maleje, o tyle dla $N \geq 2 \cdot 10^5$ pudełka przestają się kurczyć i zbiegać do czerwonej linii. Mediana trwale układa się powyżej wartości oczekiwanej, a na dole pojawiają się statyczne outliers. Udowadnia to, że algorytm uległ zapętlению i powiela z określoną częstotliwością te same, obciążone błędem punkty, przez co wariancja przestaje maleć mimo dokładania kolejnych losowań.
- Wykresy dla generatorów *linear* i *affine* są ponownie swoimi idealnymi kopiami (włączając w to długość wąsów dla $N = 10^2$), co definitywnie potwierdza brak dywergencji cykli dla testowanych parametrów startowych.
- Dla niewielkich wartości liczby losowań różnice pomiędzy generatorami są bardziej widoczne, co wynika z większej losowej zmienności oraz potencjalnych różnic w jakości generowanych sekwencji.
- Generator *inv* charakteryzuje się niewielkim rozrzutem typowych wartości estymacji (mały rozstęp międzykwartylowy), jednak dla małych wartości N pojawiają się sporadyczne wartości odstające.

6. Analiza złożoności obliczeniowej i czasu wykonania

Dokonując estymacji, dążymy do osiągnięcia jak najdokładniejszego przybliżenia, praktycznie nierozróżnialnego od oczekiwanej wartości. Należy jednak zwrócić uwagę na inny istotny parametr - złożoność obliczeniową. Algorytmy Monte Carlo opierają się na wielokrotnych losowaniach, przez co ich czas wykonania może być stosunkowo długi. Czas generowania ogromnych ciągów liczb pseudolosowych przekłada się na obciążenie jednostki obliczeniowej i czas oczekiwania na wynik. Postawione zatem zostało pytanie badawcze: czy dobór generatora ciągu liczb pseudolosowych ma znaczący wpływ na czas losowania.



Rysunek 6. Łączny czas generowania 10 serii danych (łącznie 10^7 punktów) w zależności od zastosowanego algorytmu.

Jak można zauważyć na powyższej figurze 6, dobór algorytmu ma znaczący wpływ na czas wykonania, skalę tego zjawiska najlepiej oddaje fakt, że różnica w czasie wykonania między skrajnymi algorytmami jest niemal dziesięciokrotna. Według badania bezdyskusyjnym liderem wydajności jest wbudowany generator biblioteczny *NumPy*, który dzięki niskopoziomowej optymalizacji wykonał zadanie w zaledwie 4.90 sekundy. Proste metody kongruencyjne (liniowa i afiniczna) wykazują zbliżone, akceptowalne czasy wykonania rzędu 10-11 sekund. Warto jednak zauważyć na różnicę pomiędzy generatorem liniowym o maksymalnym okresie, a generatorem afinicznym - z poprzednich badań wynikało, że wyniki ich działań są tożsame, natomiast przy analizie wydajności można zauważyć, że czas wykonania algorytmu afinicznego dla takiej samej liczby punktów jest o niemal sekundę dłuższy. Z kolei próba wzbogacenia własności statystycznych poprzez wprowadzanie nieliniowości drastycznie zwiększa narzut obliczeniowy. Generator wielomianowy wymagał niemal 31 sekund, a najbardziej złożony matematycznie generator inwersyjny, zmuszony do ciągłego wyznaczania odwrotności modulo w ciele skończonym, potrzebował aż ponad 44 sekund na wygenerowanie tej samej puli danych. Analiza ta doskonale obrazuje klasyczny w informatyce kompromis pomiędzy matematycznym skomplikowaniem algorytmu a jego optymalizacją sprzętową i kosztem czasowym.

PODSUMOWANIE I WNIOSKI

Głównym celem niniejszej pracy było zbadanie skuteczności metody Monte Carlo w estymacji wartości liczby π oraz ocena dynamiki zbieżności uzyskiwanych wyników wraz ze wzrostem liczby prób. Przeprowadzone analizy jednoznacznie potwierdziły, że metoda Monte Carlo stanowi poprawne i skuteczne narzędzie do numerycznego przybliżania wartości stałych geometrycznych, opierające swoje działanie na probabilistycznej interpretacji relacji pól figur oraz na własnościach statystycznych dużych prób losowych.

Uzyskane wyniki potwierdziły zgodność zachowania estymatora z teoretycznymi podstawami metody. Wraz ze wzrostem liczby losowań następowało systematyczne zmniejszanie błędu bezwzględnego oraz wyraźna stabilizacja estymowanej wartości wokół rzeczywistej liczby π . Dla małych wartości N estymacja cechowała się dużą zmiennością i podatnością na przypadkowe fluktuacje, co jest naturalną konsekwencją losowego charakteru metody. Jednak już dla większych liczebności prób widoczna była charakterystyczna zbieżność do wartości oczekiwanej, zgodna z Prawem Wielkich Liczb. Oznacza to, że mimo prostoty konstrukcyjnej algorytmu, jego skuteczność rośnie wraz z liczbą realizacji, a przypadkowe odchylenia ulegają stopniowemu wygaszeniu.

Szczególnie istotnym rezultatem pracy było potwierdzenie, że metoda Monte Carlo nie dostarcza pojedynczego „dokładnego” wyniku w sensie deterministycznym, lecz buduje przybliżenie o jakości zależnej od rozmiaru próby. Właśnie ta zależność stanowi jednocześnie największe ograniczenie i największą siłę tej metody: z jednej strony osiągnięcie wysokiej precyzji wymaga bardzo dużej liczby losowań, z drugiej jednak metoda pozostaje niezwykle uniwersalna, intuicyjna i łatwa do zastosowania nawet w problemach, dla których bezpośrednie rozwiązania analityczne byłyby trudne lub niemożliwe do uzyskania. W kontekście estymacji liczby π wykazano, że już dla prób rzędu $N \in [10^5, 10^6]$ uzyskiwane wyniki stają się stabilne, a błąd estymacji przyjmuje niewielkie wartości, co potwierdza praktyczną użyteczność tej techniki.

Przeprowadzenie 10 niezależnych serii symulacyjnych pozwoliło dodatkowo wykazać, że obserwowana zbieżność nie była efektem pojedynczej korzystnej realizacji, lecz miała charakter systematyczny i powtarzalny. Analiza wielu przebiegów pokazała, że wraz ze wzrostem liczby prób maleje nie tylko błąd pojedynczej estymacji, lecz również rozrzut wyników pomiędzy seriami. Tym samym potwierdzono, że metoda Monte Carlo, mimo swojej stochastycznej natury, przy odpowiednio dużej liczbie losowań prowadzi do wyników stabilnych statystycznie i wiarygodnych obliczeniowo.

Dodatkowym elementem pracy było porównanie wpływu różnych generatorów liczb pseudolosowych na jakość estymacji. Analiza ta miała charakter uzupełniający względem głównego celu badania, jednak pozwoliła rozszerzyć interpretację wyników o aspekt praktycznej implementacji algorytmu. Wykazano, że dla generatorów poprawnych strukturalnie uzyskiwane wyniki były do siebie zbliżone i prowadziły do tej samej ogólnej konkluzji: wzrost liczby prób poprawia dokładność estymacji i redukuje wariancję wyników. Jednocześnie zauważono, że jakość generatora może wpływać na tempo stabilizacji, rozrzut wyników oraz odporność na niepożądane zjawiska, takie jak na przykład przedwczesna okresowość.

Na szczególną uwagę zasługuje fakt, że słaba jakość generatora pseudolosowego może zaburzyć działanie metody Monte Carlo, nawet jeśli sama procedura estymacji pozostaje poprawna matematycznie. Pokazuje to, że w algorytmach probabilistycznych źródło danych losowych jest istotnym składnikiem wpływającym na rzetelność wyników. Z drugiej strony badanie wykazało również, że dla wielu praktycznych zastosowań nawet bardzo proste, ale dobrze dobrane generatory są wystarczające do uzyskania poprawnych i stabilnych rezultatów.

Podsumowując, przeprowadzona analiza potwierdziła zarówno teoretyczną poprawność, jak i praktyczną skuteczność metody Monte Carlo w zadaniu estymacji liczby π . Metoda ta dobrze ilustruje, w jaki sposób z prostego eksperymentu losowego można uzyskać wiarygodne przybliżenie wielkości matematycznej o fundamentalnym znaczeniu. Ostatecznym wnioskiem płynącym z pracy jest stwierdzenie, że kluczowym czynnikiem decydującym o jakości estymacji pozostaje liczba prób, oraz jakość wybranego generatora - istotną z punktu widzenia jakości numerycznej i wydajności, lecz wtórną wobec samej zasady działania metody Monte Carlo.

LITERATURA

Prof. dr hab. inż. Norbert Skoczylas (2026). Inteligencja obliczeniowa w analizie danych. Treść wykładu Algorytmy "czysto"probabilistyczne. Wydział Geologii, Geofizyki i Ochrony Środowiska, AGH, Kraków.

Wlaz, P. (2025). *Symulacje Monte Carlo. Teoria i zastosowania.*