

Zastosowanie algorytmów ewolucyjnych w rozwiązaniu problemu komiwojażera dla optymalizacji tras między automatami paczkowymi

Akademia Górniczo-Hutnicza im. Stanisława Staszica w Krakowie

Wydział Geologii, Geofizyki i Ochrony Środowiska

Inteligencja obliczeniowa w analizie danych

Opracowanie: Kajetan Kowalski¹

Streszczenie: W niniejszej pracy przeanalizowano Asymetryczny Problem Komiwojażera w kontekście optymalizacji tras kurierskich pomiędzy automatami paczkowymi, mającej na celu minimalizację całkowitego dystansu, a w konsekwencji redukcję zużycia paliwa i czasu dostaw. Badania przeprowadzono z wykorzystaniem w pełni zparametryzowanych modeli Algorytmu Genetycznego oraz Algorytmu Mrówkowego, operujących na rzeczywistych współrzędnych geograficznych i asymetrycznej macierzy kosztów uwzględniającej faktyczną topologię dróg miejskich. Porównanie obu metaheurystyk umożliwiło ocenę ich dynamiki oraz efektywności w radzeniu sobie ze złożonością przestrzenną. Uzyskane rezultaty potwierdziły wysoką skuteczność zaimplementowanych metod, wykazując ich zdolność do generowania wysoce zoptymalizowanych i logistycznie spójnych cykli operacyjnych.

WPROWADZENIE

1.1. Cel i zakres projektu

Główny cel, który został postawiony przy realizacji niniejszego projektu jest opracowanie narzędzia do wyznaczania optymalnej trasy kurierskiej łączącej N losowych w zadanym obszarze automatów paczkowych. W dobie rozkwitu i znakomitej popularności sektora e-commerce, logistyka takich procesów stała się jednym z najbardziej kosztownych i skomplikowanych etapów dostaw, bowiem każdy nadmiarowy kilometr wiąże się ze stratami zarówno ekonomicznymi jak i czasowymi. W związku z powyższym fundamentalnym celem projektu jest minimalizacja funkcji kosztu, wyrażonej jako całkowita długość pokonanej trasy.

Problem komiwojażera jest klasycznym zagadnieniem optymalizacyjnym, który analizuje się często na modelach abstrakcyjnych, opartych na odległościach nieodzwierciadlających rzeczywistości prostymi na płaszczyźnie. Niniejsza praca wychodzi poza ten schemat, nadając analizie charakter praktyczny i realistyczny. Zamiast operować na uproszczonych współrzędnych, model osadzono w rzeczywistej topologii zadanego parametrem miasta. Implementacja wykorzystuje dane o przybliżonej geometrii dróg opartej o grafową reprezentację sieci drogowej oraz ich ograniczeń prawnych, takich jak na przykład występowanie ulic jedno kierunkowych. Mimo nieunikalnych uproszczeń, model stanowi istotny krok w stronę odzwierciedlenia rzeczywistych warunków pracy logistyki miejskiej. Pozwala on na rzetelną ocenę skuteczności algorytmów ewolucyjnych w środowisku znacznie bardziej złożonym niż teoretyczne zbiory danych.

¹kajetankow@student.agh.edu.pl, Nr indeksu: 421071, Kierunek Inżynieria i Analiza Danych, Etap studiów: 3 Rok, VI Semestr, Grupa ćwiczeniowa: 1

1.2. Definicja problemu komiwojażera

Problem Komiwojażera to klasyczne zagadnienie optymalizacji kombinatorycznej, polegające na wyznaczeniu cyklu Hamiltona o minimalnej wadze w pełnym grafie ważonym. W kontekście projektu celem jest znalezienie najkrótszej trasy łączącej N punktów (np. automatów paczkowych), odwiedzającej każdy punkt dokładnie raz i kończącej się w miejscu startu.

Istota optymalizacji tras w logistyce wynika z faktu, że transport może stanowić od 30% do nawet 60% całkowitych kosztów logistycznych przedsiębiorstwa (Ziółkowski et al. (2018)). Każda redukcja dystansu bezpośrednio przekłada się na obniżenie kosztów paliwa, mniejsze zużycie floty oraz skrócenie czasu pracy kuriera. W analizowanym przypadku kurier, wyruszając z bazy (węzeł 0), musi odwiedzić wszystkie wyznaczone punkty dokładnie raz i powrócić do punktu wyjścia, co czyni to zadanie kluczowym elementem planowania tejże logistyki.


TEORETYCZNE PODSTAWY ALGORYTMÓW GENETYCZNYCH

Algorytmy genetyczne wywodzą się z szerokiej dziedziny obliczeń ewolucyjnych i stanowią grupę metod o największym znaczeniu wśród modeli inspirowanych biologią (Flasiński (2018)). Koncepcja algorytmu genetycznego została spopularyzowana m.in. przez J. Hollanda w jego monografii z 1975 roku. Algorytmy te stanowią jakościowe rozwinięcie heurystycznych metod poszukiwania, a ich głównym wyróżnikiem jest zdolność do poszukiwania rozwiązania globalnego. Dzięki temu są one znacznie bardziej odporne na ryzyko utknięcia w ekstremach lokalnych niż klasyczne metody optymalizacji. W przypadku algorytmów ewolucyjnych przestrzeń potencjalnych rozwiązań przeszukiwana jest przez wiele punktów jednocześnie - punkty te nazywamy osobnikami. Każdy osobnik reprezentuje konkretne rozwiązanie problemu, a ich zbiór tworzy populację, stanowiącą pulę genetyczną algorytmu. Zgodnie z mechanizmami znanymi z natury, w procesie ewolucji dokonuje się selekcji osobników rodzicielskich. Stosuje się w tym celu różne techniki, np. metodę koła ruletki, która zwiększa prawdopodobieństwo wylosowania osobników o lepszym przystosowaniu, przy jednoczesnym zachowaniu szansy na przetrwanie osobników słabszych (co sprzyja różnorodności genetycznej). Występujące po sobie populacje, definiowane w kolejnych iteracjach algorytmu, nazywamy pokoleniami. Kluczowe dla działania algorytmu jest rozróżnienie dwóch pojęć:

- **Genotyp:** struktura zakodowanych parametrów osobnika (w tym przypadku jest to pojedyncza wygenerowana trasa).
- **Fenotyp:** zbiór konkretnych wartości parametrów podlegających ocenie (w niniejszym projekcie jest to konkretna sekwencja automatów paczkowych tworząca trasę).

Jakość każdego osobnika oceniana jest za pomocą funkcji przystosowania. W analizowanym problemie komiwojażera funkcja ta jest zdefiniowana jako odwrotność lub ujemna wartość całkowitej długości trasy - dążymy bowiem do jej minimalizacji.

Schemat działania algorytmu genetycznego przedstawiono na Rysunku 1.



Rysunek 1. Schemat algorytmu genetycznego Flasiński (2018)

Proces rozpoczyna się od wygenerowania losowej populacji początkowej. Następnie dokonuje się oceny osobników i ich selekcji. Wybrane osobniki tworzą populację rodzicielską, na której operują dwa główne operatory genetyczne:

- **Operator krzyżowania:** polega na wymianie fragmentów chromosomów pomiędzy rodzicami, co pozwala na łączenie cech dobrych rozwiązań w celu wytworzenia potencjalnie lepszego potomstwa.
- **Operator mutacji:** polega na losowej zmianie wartości pojedynczego genu (lub zamianie miejscami genów w przypadku kodowania permutacyjnego). Jest to kluczowy etap pozwalający na wprowadzenie do populacji nowej informacji genetycznej i zapobieganie przedwczesnej zbieżności algorytmu.

Po utworzeniu nowej populacji potomnej następuje ponowna ocena przystosowania. Proces ten jest powtarzany iteracyjnie aż do momentu osiągnięcia warunku zatrzymania (np. uzyskania satysfakcjonującego wyniku lub wykonania założonej liczby pokoleń).

POZYSKANIE DANYCH PRZESTRZENNYCH

Jednym z głównych założeń realizowanego projektu było postawienie na jak największą potencjalną użyteczność oraz realistyczność, poprzez wyjście poza sferę czysto teoretycznych modeli euklidesowych. Aby algorytmy optymalizacyjne mogły dostarczyć wartościowych wyników, konieczne było pozyskanie precyzyjnych danych lokalizacyjnych punktów odbioru oraz danych reprezentujących infrastrukturę drogową danego miasta.

3.1. Ekstrakcja lokalizacji automatów paczkowych


Kluczowym etapem prac, stanowiącym fundament całej analizy logistycznej, jest ekstrakcja danych lokalizacyjnych zautomatyzowanych punktów odbioru przesyłek. Zgodnie z metodyką analizy danych przestrzennych, do pozyskania rzeczywistych informacji geograficznych wykorzystano biblioteki geo-przestrzenne oraz interfejs programistyczny OpenStreetMap. W ramach projektu zaimplementowano autorską funkcję `get_paczkomat()`, której zadaniem jest kompleksowe przetwarzanie oraz obsługa danych strumieniowanych z API.

Wszystkie pobierane obiekty poddawane są transformacji współrzędnych do układu płaskich prostokątnych **EPSG:2180**. Operacja ta jest niezbędna, aby przejść z jednostek kątowych na jednostki metryczne, co w dalszych etapach projektu pozwala na precyzyjne wyznaczanie rzeczywistych odległości drogowych pomiędzy poszczególnymi punktami. Dane źródłowe pobierane są bezpośrednio z serwerów OpenStreetMap (OSM) przy użyciu precyzyjnie zdefiniowanego zestawu tagów. Pozwala to na skuteczne wyodrębnienie automatów paczkowych konkretnych operatorów z rozbudowanej bazy obiektów punktowych.

Na podstawie szczegółowej analizy struktury bazy danych OSM ustalono, że kluczowymi parametrami identyfikującymi poszukiwane obiekty są pary klucz-wartość: `amenity: parcel_locker` oraz `amenity: vending_machine`, przy jednoczesnym doprecyzowaniu przeznaczenia urządzenia poprzez tag `vending: parcel_pickup`. Implementacja parametru `operator_name` umożliwia dynamiczne filtrowanie automatów należących do różnych firm kurierskich (np. InPost), co pozwala na dostosowanie narzędzia do indywidualnych potrzeb użytkownika lub specyfiki badanego operatora.

Istotnym elementem procedury jest etap losowania punktów z puli dostępnych lokalizacji. Choć wprowadza on element pewnego uproszczenia względem rzeczywistych scenariuszy kurierskich, został zdefiniowany w ten sposób, aby zapewnić obiektywność testowanych algorytmów. Takie podejście zapobiega manualnemu, subiektywnemu determinowaniu punktów, co mogłoby prowadzić do sztucznego zawyżenia lub zaniżenia efektywności algorytmu optymalizacyjnego. Program losuje określoną liczbę punktów (`N_POINTS`) w obrębie poligonu ograniczającego, reprezentującego granice administracyjne badanego miasta.

Finalnym wynikiem działania opisanej funkcji jest uporządkowana struktura danych. Zawiera ona unikalny identyfikator punktu, jego kod referencyjny, nazwę oraz precyzyjne współrzędne w układzie kartezjańskim (x, y) . Tak przygotowany zbiór danych stanowi bezpośredni wkład do dalszych etapów analizy oraz implementacji algorytmów ewolucyjnych.



Rysunek 2. Wizualizacja wylosowanych Paczkomatów InPost w Krakowie.


3.2. Wyznaczenie punktu początkowego trasy kuriera

Kolejnym istotnym elementem modelowania rzeczywistego procesu logistycznego było zdefiniowanie punktu początkowego trasy, pełniącego rolę bazy lub sortowni, z której kurier rozpoczyna pracę. Wprowadzenie stałego punktu startowego miało na celu nie tylko urealistycznienie symulacji, ale także zapewnienie spójności danych i analiz dla różnych scenariuszy geograficznych. Należy jednak zaznaczyć, że pozyskanie uniwersalnej informacji o lokalizacji baz logistycznych dla każdego miasta w Polsce jest zadaniem złożonym ze względu na dużą różnorodność tagowania obiektów w bazie OpenStreetMap.

W ramach projektu zaimplementowano funkcję *get_sortownia()*, która realizuje hierarchiczną procedurę poszukiwania punktu startowego. W pierwszej kolejności system przeszukuje bazę danych pod kątem placówek oznaczonych tagiem `amenity: post_office`, przypisanych do konkretnego operatora. W przypadku braku wyników, algorytm podejmuje próbę lokalizacji obiektów przemysłowo-logistycznych (`post_depot` lub `industrial: logistics`). Takie podejście pozwala na automatyczne odnalezienie rzeczywistej infrastruktury operatora, o ile została ona skatalogowana w otwartych zbiorach danych przestrzennych.

Ze względu na różną szczegółowość mapowania w mniejszych miejscowościach, wprowadzono mechanizm awaryjny. Jeśli w badanym regionie nie uda się zlokalizować dedykowanej placówki operatora, funkcja przyjmuje za punkt startowy lokalizację pierwszego wylosowanego automatu paczkowego. W skrajnych przypadkach, gdy zbiór punktów jest pusty (tzn. miejscowość nie posiadająca nawet jednej skrytki pocztowej), system wyznacza punkt początkowy w geometrycznym środku poligonu ograniczającego badaną miejscowość. Gwarantuje to ciągłość działania algorytmu niezależnie od obranego przez użytkownika obszaru.

Ostatnim etapem przygotowania danych jest integracja punktu startowego z listą docelowych automatów paczkowych w jedną strukturę *GeoDataFrame*. Proces ten wymagał implementacji logiki zapobiegającej duplikacji punktów: w sytuacji, gdy baza logistyczna została wyznaczona na podstawie pierwszego automatu paczkowego (*first_paczkomat_fallback*), punkt ten jest usuwany z listy celów do odwiedzenia, aby uniknąć błędnego zapętlenia trasy w tym samym miejscu. Finalnie wszystkie obiekty są łączone, a ich identyfikatory są reindeksowane, tworząc spójną macierz współrzędnych gotową do obliczeń dystansu.



Rysunek 3. Punkt startowy na przykładzie placówki pocztowej InPost w Krakowie.

3.3. Ekstrakcja węzłów drogowych i wyznaczenie macierzy odległości.

Kolejnym etapem jest odwzorowanie sieci drogowej jako grafu skierowanego, co pozwala na uwzględnienie rzeczywistych ograniczeń ruchu. W tym celu, przy użyciu biblioteki *OSMNX*, pobrano graf dróg dla badanego regionu z parametrem `network_type="drive"`. Wybór tego typu sieci jest kluczowy dla urealistycznienia modelu, ponieważ uwzględnia on wyłącznie drogi dostępne dla samochodów dostawczych, respektując przy tym kierunkowość ulic oraz topologię skrzyżowań. Pobrany graf został poddany reprojektacji do układu **EPSG:2180**, co zapewnia spójność z wcześniej przygotowanymi lokalizacjami automatów paczkowych.

Dalej wykonuje się mapowanie lokalizacji automatów paczkowych na strukturę grafu drogowego. Ponieważ punkty pobrane z bazy OSM nie zawsze leżą idealnie w osiach jezdni, zastosowano funkcję `nearest_nodes`, która przypisuje każdy automat do najbliższego węzła w sieci drogowej. Operacja ta stanowi niezbędne przybliżenie techniczne, pozwalające na włączenie punktów odbioru do analizy grafowej. W wyniku tego procesu każdy automat paczkowy oraz sortownia stają się konkretnymi węzłami w grafie, pomiędzy którymi możliwe jest wyznaczanie tras o najniższym koszcie przy użyciu algorytmu Dijkstry.

Należy jednak wskazać na pewne ograniczenia i uproszczenia wynikające z charakteru dostępnych danych technicznych oraz samej struktury grafowej. Przypisanie automatów do najbliższych węzłów, a nie do najbliższych punktów na krawędziach dróg, wprowadza pewien błąd systematyczny. W rzeczywistości automat może znajdować się w połowie długiego odcinka drogi, podczas gdy model wymusza dojazd do jego najbliższego zakończenia (skrzyżowania lub zwrotu). Dodatkowo, geometria dróg w grafie bywa uproszczona - odcinki łączące węzły są często reprezentowane jako linie proste, podczas gdy realna droga może przebiegać łukiem. Wynika to z gęstości próbkowania węzłów w bazie OpenStreetMap. Rzadsze rozmieszczenie punktów w bazie bowiem skutkuje mniejszą precyzją w odwzorowaniu rzeczywistego przebiegu trasy i jej długości.

Rysunek 4. Wizualizacja niedokładności danych sieci drogowej. Kolor czerwony: odległość rzutowania punktu na węzeł grafu. Kolor niebieski: wyznaczona trasa grafowa wykazująca brak pokrycia z rzeczywistym łukiem drogi.

W celu przygotowania danych wejściowych dla algorytmów optymalizacyjnych, zaimplementowano funkcję `build_routing_data()`, która przekształca rzadki graf drogowy w pełną macierz kosztów. Wykorzystano funkcję `single_source_dijkstra`, która dla każdego węzła startowego wyznacza dystanse do wszystkich pozostałych celów. Jako wagę krawędzi przyjęto długość odcinków dróg. Wynikiem opisanych operacji jest dwuwymiarowa macierz kosztów (odległości) oraz słownik ścieżek (*path_cache*). Taka struktura pozwala oddzielić etap złożonych obliczeń grafowych od samej procedury optymalizacji ewolucyjnej, co znacząco przyspiesza działanie systemu.

[illegible]

Rysunek 5. Macierz kosztów pomiędzy poszczególnymi punktami.

Powyżej zestawiono kompletną macierz odległości wyznaczoną dla wszystkich analizowanych punktów. Ze względu na znaczną liczbę danych oraz konieczność dopasowania tabeli do szerokości strony, została ona poddana istotnemu skalowaniu. W celu odczytania szczegółowych wartości oraz analizy poszczególnych komórek macierzy, zaleca się przybliżenie dokumentu.

IMPLEMENTACJA I ANALIZA ALGORYTMU GENETYCZNEGO

Po zaprezentowaniu podstaw teoretycznych, oraz danych na których analiza i optymalizacja się opierają, nadszedł moment implementacji samego algorytmu genetycznego. Stanowi on sendo realizacji projekt, gdyż to jego implementacja zapewnia optymalne przeszukanie mapy i spośród olbżymiej przestrzeni dostępnych rozwiązań jest w stanie znaleźć te najbardziej optymalne. Zastosowana metaheurystyka opiera się na ewolucyjnym doskonaleniu tras kurierskich, wykorzystując mechanizmy selekcji, rekombinacji oraz mutacji. Niniejsza sekcja poświęcona została dogłębnemu technicznemu opisowi wprowadzonego rozwiązania.

4.1. Implementacja Algorytmu Genetycznego

4.1.1. Reprezentacja osobnika i inicjalizacja populacji

Zgodnie z wprowadzonymi wcześniej definicjami należy opowiedzieć co rozumiemy poprzez zastosowane elementy GA. Pojedynczy osobnik, tudzież chromosom jest reprezentowany jako permutacja unikalnych indeksów punktów automatów paczkowych. Genotyp osobnika zaś jest listą liczb całkowitych, gdzie pierwszy gen jest zwawsze stały `start_idx = 0` - odpowiada on punktowi startowemu (sortowania/punkt pocztowy/pierwszy punkt w obrębie), który niezależnie od trasy, jest niezmienny. Pozostałe geny są losowo mieszane podczas inicjalizacji, co pozwala na wygenerowanie zróżnicowanej populacji początkowej o rozmiarze zadany parametrem `population_size` w baanym przypadku, w wyniku optymalizacji ustawionego na wartość 200. Taka liczebność zapewnia odpowiedni poziom zróżnicowania zapewnia odpowiedni poziom zróżnicowania genetycznego już na starcie systemu.

4.1.2. Funkcja przystosowania

Funkcja przystosowania innymi słowy jest to funkcja oceny bądź dopasowania. W tej pracy owa funkcja jest bezpośrednio związana z minimalizacją kosztu trasy. Jakość każdego osobnika oceniana jest poprzez sumowanie wag krawędzi odczytanych z macierzy kosztów `cost_matrix`. Obliczana trasa obejmuje przejazd przez wszystkie wyznaczone punklty, oraz obligatoryjny powrót do punktu startowego.

Model dąży do znalezienia wartości:

$$\min \sum_{i=0}^{n-1} \text{cost}(p_i, p_{i+1})$$

,gdzie p to sekwencja punktów w chromosomie, a $p_n = p_0$.


4.1.3. Selekcja - metoda ruletki z zrupowaniem

W celu wyboru osobników rodzicielskich do reprodukcji zastosowano metodę ruletki opartą na rankingu `roulette_group_selection`. Mechanizm selekcji zamiast operować na surowych wartościach funkcji celu, nadaje rangi r na podstawie posortowanej jakości. Dzięki tamkiemu zastosowaoaniu prawdopodobieństwo wyboru P_k zależy od współczynników a oraz b zdefiniowanych w wyniku optymalizacji jako kolejno 0.10 oraz 0.90.

Prawdopodobieństwo wyboru P_k oblicza się zgodnie z formułą Prof. dr hab. inż. Norbert Skoczylas (2026a):

$$P_k = a + b \cdot \left(\frac{r_k}{r_{opt}} \right)$$


Takie podejście promuje trasy o najlepszej wartości funkcji dopasowania, ale równocześnie daje szansę słabszym osobnikom, aby również uczestniczyły w procesie dziedziczenia, co chroni populację przed utknięciem w minimach lokalnych.



Rysunek 6. Schemat przykładowej selekcji metodą ruletki z zastosowaniem rankingowania. Ilustracja przedstawia sposób transformacji kosztu trasy na prawdopodobieństwo wyboru osobnika do nowej populacji rodzicielskiej (opracowanie własne).

4.1.4. Operator mutacji - Inwersja

Mutacja jest kluczowym elementem przyczyniającym się do powstawania nowych genów w populacji, a co za tym idzie potencjalnych lepszych rozwiązań do tej pory nieistniejących. Istnieje wiele metod mutacji, które zostały poddane badaniu: podmienienie, wstawienie, inwersja. Po przeanalizowaniu różnych scenariuszy, dla badanego przypadku najlepsze wyniki dawała mutacja poprzez inwersję. Polega ona na wylosowaniu dwóch punktów w chromosomie i odwróceniu kolejności genów znajdujących się pomiędzy nimi. Inwersja jest znacznie skuteczniejsza w problemie TSP niż prosta zamiana genów, ponieważ pozwala na efektywniejszą zmianę lokanych struktur ścieżki. Predefiniowane prawdopodobieństwo mutacji w prezentowanym rozwiązaniu wynosi $\text{mutation_rate} = 0.15$.



Rysunek 7. Schemat działania operatora mutacji inwersyjnej. Ilustracja przedstawia proces na chromosomie reprezentującym trasę. Z lewej strony widoczny jest pierwotny genotyp, w którym wylosowano spójny segment do odwrócenia. Z prawej strony przedstawiono wynikowy chromosom po operacji, w którym kolejność genów (paczkomatów) w wybranym fragmencie została odwrócona, tworząc nową, unikalną strukturę przy zachowaniu poprawności permutacji (opracowanie własne).

4.1.5. Sukcesja elitarna oraz warunek stopu

Algorytm wykorzystuje strategię elitarną z parametrem `elite_size = 6` - oznacza to, że sześć najlepszych osobników z każdego pokolenia przechodzi do następnego w niezmienionej formie. Gwarantuje to, że wypracowane dotychczas najlepsze rozwiązanie nie zostanie utracone w wyniku operacji losowych. W zaprezentowanym rozwiązaniu ewolucja trwa do momentu osiągnięcia 5000 pokoleń (aby nie wpaść w nieskończoną pętlę) lub wystąpienia stagnacji, rozumianej jako brak poprawy najlepszego wyniku przez określoną liczbę generacji `stagnation_limit = 60`.

4.2. Analiza wyników działania Algorytmu Genetycznego

Po dokładnej analizie zasad działania algorytmu, należy zweryfikować skuteczność zaimplementowanego rozwiązania oraz przeanalizować uzyskane wyniki optymalizacji trasy kuriera w aglomeracji miejskiej.

4.2.1. Analiza porównawcza stanu początkowego i końcowego

Aby porównać efektywność pracy, najlepiej jest zestawić losowy stan początkowy pierwszej populacji, z wynikiem uzyskanym w ostatniej generacji procesu ewolucyjnego.

- **Koszt startowy (najlepszy z losowej populacji):** 237 209,39 m
- **Koszt końcowy (zoptymalizowany):** 114 015,60 m
- **Liczba pokoleń:** 501
- **Warunek zatrzymania:** Stagnacja (60 pokoleń bez poprawy wyniku)

Różnica między stanem początkowym a końcowym zatem wynosi **123 193,79 m**, co oznacza poprawę o **51,93%** względem najlepszej trasy znalezionej w procesie inicjalizacji. Tak znacząca redukcja dystansu (ponad połowa pierwotnej trasy) jednoznacznie dowodzi wysokiej skuteczności zastosowanej metaheurystyki w rozwiązywaniu problemów o dużej złożoności obliczeniowej.




Rysunek 8. Wizualizacja trasy przed optymalizacją (najlepszy osobnik populacji początkowej). Charakterystyczny jest wysoki stopień chaotyczności, liczne pętle oraz nielogiczne powroty.



Rysunek 9. Wizualizacja trasy po zakończeniu procesu optymalizacji.

Po dogłębnej analizie przedstawionych map oraz informacji dotyczących długości tras można zauważyć, że wynik procesu optymalizacji jest bardzo satysfakcjonujący. Przebieg trasy, który początkowo miał charakter chaotyczny, w kolejnych iteracjach został uporządkowany i przyjął bardziej logiczną strukturę.

Warto również zwrócić uwagę na dynamikę samego procesu optymalizacji, w szczególności na zmiany wartości funkcji kosztu w czasie. Analiza przebiegu funkcji kosztu dla najlepszego, najgorszego oraz średniego osobnika w kolejnych generacjach pozwala lepiej zrozumieć skuteczność zastosowanego algorytmu oraz tempo jego zbieżności.



Rysunek 10. Wykres zbieżności algorytmu genetycznego.

Analiza wykresu zbieżności (Rys. 10) pozwala na wyciągnięcie wniosków dotyczących dynamiki i specyfiki pracy algorytmu genetycznego oraz skuteczności przyjętych operatorów.

W początkowej fazie ewolucji (generacje 0-100) zaobserwować można gwałtowny, niemal wykładniczy spadek wszystkich 3 wartości (kosztu najlepszego, najgorszego i uśrednionego). Świadczy to tym że algorytm szybko eliminuje drastyczne i najbardziej rażące błędy w trasach. Około 200. generacji algorytm osiąga znacznie niższą wartość kosztu, niż wartość początkowa, wchodząc w fazę stabilizacji. Można zauważyć, że interesująca nas krzywa najlepszego kosztu (kolor niebieski) wypłaszcza się, co może wskazywać na utknięcie w minimum lokalnym.

W okolicy pomiędzy 330. a 400. generacją można zauważyć interesujące skoki wartości kosztu - są one kluczowym momentem uzyskania ostatecznego wyniku. Widoczne na wykresie fałdy są wynikiem wprowadzonej presji mutacyjnej. Nagły wzrost średniego kosztu świadczy o tym, że algorytm zaczął wprowadzać do populacji znaczące zmiany, drastycznie zmieniając strukturę dotychczasowych tras. Jak się zatem okazuje lokalne pogorszenia wyniku, są zjawiskiem pożądanym, które wyprowadza nas z minimum lokalnego. Można by je porównać do rozkołysania wózka, który utknął w dolinie, aby się z niej wydostać. Algorytm celowo "psuje" część rozwiązań, aby wytrwać je z obecnego schematu, który przestał przynosić poprawę. Efekt tego zachowania można zauważyć od 400. generacji, gdzie udało się osiągnąć jeszcze bardziej optymalną trasę.

Podsumowując, systematyczna stabilizacja przeplatana kontrolowanym chaosem pozwoliła na osiągnięcie ostatecznego wyniku 114 km. Mechanizm ten potwierdza, że odpowiedni dobór prawdopodobieństwa mutacji (15%) oraz inwersji jest kluczem do sukcesu - bez mutacji algorytm prawdopodobnie zakończyłby pracę znacznie wcześniej, z wynikiem oscylującym wokół 130 km. Można uznać, że każda taka fluktuacja była inwestycją, która zwróciła się w postaci finalnej optymalizacji o dodatkowe kilkanaście kilometrów.

4.2.2. Weryfikacja uniwersalności algorytmu


Opracowany system charakteryzuje się pełną uniwersalnością i parametrycznym podejściem do danych wejściowych, co pozwala na jego adaptację do zróżnicowanych scenariuszy logistycznych. Architektura rozwiązania umożliwia wyznaczanie optymalnych tras dla szerokiego spektrum operatorów (InPost, Allegro, DPD, Orlen Paczka czy DHL) w obrębie dowolnej lokalizacji geograficznej na terenie Polski.

Istotnym elementem walidacji algorytmu była weryfikacja jego stabilności i efektywności w zmiennych warunkach brzegowych. Choć zasadniczy proces optymalizacji parametrów ewolucyjnych przeprowadzono wyłącznie na przykładzie sieci Paczkomatów InPost w Krakowie, system został poddany testom sprawdzającym również dla innych jednostek terytorialnych. Bez dodatkowej rekonfiguracji kodu, przeprowadzono analizy dla miast o różnej skali i specyfice (Warszawa, Rzeszów, Stalowa Wola), charakteryzujących się odmienną topologią sieci drogowej oraz zróżnicowanym zagęszczeniem punktów odbioru (Rys. 11). Pozwoliło to na obiektywną ocenę skalowalności zaimplementowanej metaheurystyki.


Analiza porównawcza wybranych miast:

- **Warszawa (Orlen Paczka):** Odnotowano najwyższy wskaźnik poprawy wynoszący aż **63,71%** (skrócenie trasy o 251,56 km). Tak wysoki wynik wynika z ogromnej złożoności przestrzeni poszukiwań w stolicy. W dużych aglomeracjach losowa trasa jest skrajnie nieefektywna, co daje algorytmowi genetycznemu pole do spektakularnych optymalizacji.
- **Rzeszów (InPost):** Uzyskano poprawę na poziomie **53,93%** (skrócenie o 80,70 km). Wynik ten jest zbliżony do rezultatów krakowskich, co sugeruje stabilność algorytmu w miastach o średniej i dużej wielkości.
- **Stalowa Wola (InPost):** W przypadku mniejszego ośrodka poprawa wyniosła **35,94%**. Niższy procentowy zysk jest zjawiskiem naturalnym - przy mniejszej liczbie punktów (N_POINTS) i mniejszym obszarze miasta, nawet trasa losowa nie jest aż tak rozbudowana, więc margines możliwej optymalizacji ulega zawężeniu.


Stalowa Wola, Paczkomaty InPost
różnica: 15.12 km, poprawa: 35.94%



Warszawa, Automaty Orlen Paczka
różnica: 251.56 km, poprawa: 63.71%



Rzeszów, Paczkomaty InPost
różnica: 80.70 km, poprawa: 53.93%



Rysunek 11. estawienie wyników optymalizacji dla różnych aglomeracji i operatorów.

4.3. Podsumowanie procesu optymalizacji ewolucyjnej

Przeprowadzona implementacja i analiza działania algorytmu genetycznego w problemie optymalizacji tras kurierskich pozwoliła na sformułowanie jednoznacznych wniosków dotyczących efektywności tej metody.

4.3.1. Kluczowe osiągnięcia i metryki

Głównym sukcesem projektu jest wypracowanie trasy o długości 114 015,60 m, co w zestawieniu z najlepszym wynikiem losowej populacji początkowej (237 209,39 m) stanowi poprawę o blisko 52%. Tak gwałtowna redukcja dystansu - uzyskana w zaledwie 501 pokoleniach - potwierdza, że algorytm genetyczny nie tylko sprawnie przeszukuje przestrzeń rozwiązań, ale również skutecznie eliminuje nieefektywne „pętle”, które w rzeczywistym transporcie generowałyby ogromne koszty operacyjne i środowiskowe.

4.3.2. Interpretacja jakości wyniku

Mimo że problem komiwojażera jest zagadnieniem NP-trudnym i teoretycznie zawsze istnieje szansa na znalezienie trasy krótszej o kilka metrów poprzez dalszą manipulację parametrami, uzyskany wynik należy uznać za w pełni satysfakcjonujący. Wygenerowana trasa cechuje się wysoką spójnością logiczną i brakiem błędów topologicznych (np. nielogicznych powrotów). Z logicznego punktu widzenia, dążenie do dalszych, marginalnych poprawek byłoby nieuzasadnione ekonomicznie względem potrzebnego nakładu czasu obliczeniowego.

Podsumowując, zaimplementowany model ewolucyjny udowodnił swoją uniwersalność i gotowość do wspierania decyzji logistycznych w rzeczywistych warunkach miejskich, niezależnie od skali miasta czy wybranego operatora.

4.3.3. Materiały uzupełniające i załączniki

W celu pełnego zobrazowania dynamiki i wyników prac, do niniejszego sprawozdania dołączono następujące materiały multimedialne:

Interaktywna mapa (HTML): Pozwala na szczegółowe prześledzenie zoptymalizowanej trasy w Krakowie na podkładzie rzeczywistej sieci drogowej wraz z punktami odbioru.

Animacja (GIF): Wizualizuje proces ewolucji pokolenie po pokoleniu, obrazując, jak algorytm stopniowo porządkuje chaotyczne połączenia początkowe w spójny, optymalny cykl dla sieci InPost.

ALTERNATYWNE PODEJŚCIE INSPIROWANE BIOLOGIĄ - ALGORYTM MRÓWKOWY

W celu zestawienia algorytmu genetycznego z innymi metodami, obok zaimplementowany zostało popularne podejście oparte na tzw. inteligencji stadnej - algorytm mrówkowy. Zgodnie z systematyką przedstawioną przez prof. Flasińskiego (Flasiński (2018)), optymalizacja mrówkowa (*Ant Colony Optimization*) stanowi składową systemów informatycznych modelowanych jako samoorganizujące się populacje autonomicznych jednostek, które oddziałują na siebie nawzajem oraz na środowisko, w którym się znajdują.

5.1. Teoretyczne podstawy algorytmu mrówkowego

5.1.1. Fundamenty inteligencji stadnej i systemy agentowe

Jednostka w takim systemie przyjmuje postać agenta - autonomicznego bytu zdolnego do transformowania obserwacji otoczenia w konkretne akcje prowadzące do osiągnięcia zadanego celu. Koncepcja ta silnie nawiązuje do systemów wieloagentowych oraz prac Craiga Reynoldsa z 1987 roku. Reynolds zdefiniował tzw. boidy, czyli sztuczne jednostki działające w stadzie w oparciu o trzy fundamentalne reguły:

- **Rozdzielność:** utrzymywanie zadanych odległości, w celu uniknięcia lokalnych zgromadzeń,
- **Spójność:** dążenie do przebywania w pobliżu środka stada, zapobiega rozproszeniu.
- **Wyrównanie:** dostosowanie kierunku i prędkości do pozostałych jednostek.

Algorytmy rojowe są unikalną klasą metod optymalizacyjnych, które naśladują zachowania populacji zwierząt w celu rozwiązywania złożonych zagadnień permutacyjnych. Ich istotą jest fakt, że proste, słabe pojedyncze osobniki, funkcjonują dzięki mechanizmom współpracy i ciągłej wymianie informacji, oraz są w stanie wypracować rozwiązanie problemów globalnych, przekraczających możliwości pojedynczego agenta.

W tym procesie kluczowe są dwa czynniki, które determinują kierunek przeszukiwania zbioru: własne doświadczenie indywidualnego osobnika, oraz wiedza zbiorowa całej populacji (najlepsza dotychczas znaleziona trasa).

5.1.2. Metaheurystyka Marco Dorigo

Algorytm mrówkowy, opracowany przez Marco Dorigo, przekłada zaobserwowane w naturze zachowania kolonii mrówek na grunt optymalizacji kombinatorycznej. Metoda ta modeluje agentów jako "sztuczne mrówki", które szukając rozwiązań w przestrzeni rozwiązań (w badanym problemie graf dróg miejskich), pozostawiając za sobą ślad feromonowy. Mechanizm działania opiera się na dwóch przeciwstawnych procesach:


1. Wzmocnienie pozytywne: ścieżki prowadzące do rozwiązań o wysokiej jakości (krótszych tras) otrzymują większą dawkę wirtualnego feromonu. Powoduje to, że w kolejnych iteracjach stado wykazuje większą skłonność do wyboru właśnie tych krawędzi.
2. Parowanie: dla miejsc o niskiej jakości lub rzadko odwiedzanych, wartości feromonowe z czasem „wyparowują”. Zapobiega to zbyt szybkiemu skupieniu się stada na rozwiązaniach suboptymalnych i pozwala na ciągłą eksplorację nowych obszarów grafu.

W procesie decyzyjnym mrówka kieruje się nie tylko śladem pozostawionym przez poprzedników, ale również lokalną atrakcyjnością celu (widoczność, η).

W problemie heurystyka ta jest definiowana jako odwrość odległości pomiędzy automatami paczkowymi:

$$\eta_{ij} = \frac{1}{d_{ij}} \quad (1)$$

Oznacza to, że mrówki mają naturalną tendencję do wybierania punktów położonych bliżej, co w połączeniu z feromonem tworzy mocny mechanizm optymalizacyjny.



Rysunek 12. Optymalizacja ścieżki w kolonii mrówek: mechanizm omijania przeszkody stanowiący fundament teoretyczny metaheurystyki Marco Dorigo (źródło: MathWorks)

5.1.3. Reguła przejścia

Prawdopodobieństwo p_{ij}^k , z jakim mrówka k znajdująca się w punkcie i wybierze jako cel swojej podróży punkt j , wyliczane jest zgodnie z modelem:

$$p_{ij}^k = \frac{[\tau_{ij}(t)]^\alpha \cdot [\eta_{ij}]^\beta}{\sum_{j \in J_i^k} [\tau_{ij}(t)]^\alpha \cdot [\eta_{ij}]^\beta} \quad (2)$$

gdzie:

τ_{ij} - feromon między punktami i i j ,

η_{ij} - widoczność punktu j z punktu i ,

d_{ij} - odległość między punktami i i j ,

$J_i^k = \{j : j \notin \text{tabu}_k\}$ - zbiór nieodwiedzonych do tej pory punktów przez prówkę k ,

α, β - parametry pozwalające użytkownikowi sterować względną ważnością intensywności śladu i widocznością punktów.

Opracowanie sekcji w oparciu o Flasiński (2018) oraz Prof. dr hab. inż. Norbert Skoczylas (2026b).

5.2. Implementacja Algorytmu Mrówkowego

Opracowany model algorytmu mrówkowego, jest oparty o teoretyczne założenia omówione w podsekcji 5.1. Jest to praktyczne rozwinięcie teoretycznych założeń inteligencji stadnej w środowisku grafu sieci drogowej, gdzie system iteracyjnie symuluje zachowanie wirtualnej kolonii mrówek. Mrówki - w roli agentów - poprzez lokalne interakcje oraz pozostawianie syntetycznego śladu feromonowego, dążą do optymalizacji trasy kuriera pomiędzy punktami dostaw.

5.2.1 Inicjalizacja środowiska

Aby przeprowadzenie działań algorytmu było owocne w skutkach, należy je poprzedzić pewnymi definicjami środowiska. Procedura generuje struktury danych niezbędnych do nawigacji agentów w oparciu o dwóch macierzach o wymiarach $N \times N$, gdzie N oznacza liczbę automatów paczkowych na trasie:

- Macierz heurystyczna (η) - reprezentująca ogólnie zadaną lokalną atrakcyjność przejścia pomiędzy kolejnymi węzłami grafu (powstała w oparciu o wzór (1)),

- Macierz feromonów (τ) - początkowo inicjowana stałą wartością 1.0 dla wszystkich dostępnych krawędzi, jest dynamicznie modyfikowana w czasie trwania cykli, w zależności od osiągniętej intensywności. Początkowe ujednolicenie grafu wpływa na to, że w pierwszych iteracjach mrówki równomiernie będą przeszukiwać całą jego przestrzeń.

5.2.2. Konstrukcja trasy i mechanizm decyzyjny

W każdym cyklu populacja mrówek składająca się z M osobników (domyślnie 60). Poszczególne mrówki rozpoczynają trasę z losowego punktu startowego spośród wszystkich znajdujących się w puli automatów paczkowych. Dzięki losowemu rozrzuceniu mrówek po całej mapie mamy zapewnione, że żadna trasa nie zostanie przypadkowo ominięta, a eksploracja mapy będzie szersza.

Kluczowym momentem życia takiej syntetycznej mrówki jest decyzja, o wyborze kolejnego punktu który ma odwiedzić. Wybór dla osobnika znajdującego się w węźle i o przejściu do kolejnego, jeszcze nieodwiedzonego węzła j , jest stochastyczny i jest determinowany zależnością opisaną równaniem (2).

Mechanizm normalizacji przekształca wartości funkcji prawdopodobieństwa w prawidłowy rozkład probabilistyczny spełniający warunek normalizacji $\sum p_i = 1$. Następnie, metoda symulująca działanie koła ruletki wybiera kolejny cel. Gwarantuje to, że krótki i intensywne feromonowo krawędzie mają największą szansę na wybór, ale jednocześnie nie eliminuje całkowicie gorszych ścieżek.

5.2.3. Parowanie i Wzmacnianie

Po zakończeniu każdego cyklu następuje aktualizacja środowiska, która zapobiega przedwczesnej zbieżności i steruje procesem uczenia. Odbyna się to w dwóch etapach:

1. **Ewaporacja** - ślad feromonowy ulega regularnemu wyaszaniu, jeżeli nie jest odwiedzany przez agentów. Mechanika ta zapobiega utknięciu mrówki w suboptymalnym lokalnym optimum. W każdym kroku wszystkie wartości w macierzy feromonów są redukowane zgodnie z formułą:

$$\tau_{ij} = \tau_{ij} * (1 - \rho) \quad (3)$$

gdzie ρ symbolizuje współczynnik parowania (w wyniku optymalizacji przyjęto wartość 0.5).

2. **Wzmocnienie** - ponieważ parowanie odbywa się niezależnie co iteracje, aby nie utracić całkowicie wszystkich ścieżek, mrówki po każdym swoim przejściu nanoszą nowy feromon. Ilość pozostawionego feromonu ($\Delta\tau$) jest wprost proporcjonalna do jakości znalezionej rozwiązania, czyli całkowitego kosztu trasy L . Dla każdej pary punktów (i, j) należących do zamkniętej trasy danej mrówki dodawana jest wartość:

$$\Delta\tau_{ij} = \frac{Q}{L} \quad (4)$$

gdzie Q to stała premia za przejście (w wyniku optymalizacji przyjęto wartość 1200). Algorytm dodatkowo uwzględnia dwukierunkowość rozwiązania, aktualizując ślad w obu kierunkach zarówno (i, j) jak i (j, i) . Trasy o mniejszym dystansie L otrzymują proporcjonalnie większy przyrost feromonu, wyznaczając trasę dla kolejnych iteracji.

5.2.4. Śledzenie historii oraz warunek stopu

Wewnątrz głównej funkcji spajającej wszystkie mechanizmy, zaimplementowano procedurę zapisującą pełną historię: macierze feromonów, najlepsze koszty oraz najkorzystniejsze ścieżki. Ma to na celu możliwość podglądu jak zmieniają się ścieżki, ich wzmocnienia i jest wykorzystywane do wizualizacji wyników algorytmu.

Na zakończenie wdrożenia trzeba mrówki w jakiś sposób ograniczyć, ponieważ bez narzuconego limitu krążyłyby po badanej miejscowości w nieskończoność. Zaimplementowany system operuje do momentu osiągnięcia jednego z dwóch warunków końcowych. Pierwszym jest wykonanie maksymalnej

dopuszczonej liczby cykli (W wyniku optymalizacji przyjęto wartość $N = 200$). Drugim jest weryfikacja zbieżności populacji. Program analizuje trasy wszystkich mrówek w danym cyklu i jeżeli wszystkie osobniki wykazują absolutny konsensus tj. wszystkie wybrały dokładnie tą samą trasę, ewolucja wówczas zostaje zatrzymana. Wynikiem jest jedna wyróżniająca się wybitnie mocną ścieżką feromonową, którą uznaje się za znalezienie rozwiązania problemu.

5.3. Analiza wyników działania Algorytmu Mrówkowego

Kolejnym etapem niniejszej pracy jest analiza i ocena skuteczności zaimplementowanego algorytmu mrówkowego oraz weryfikacja jego zdolności do optymalizacji tras w aglomeracji miejskiej.

5.3.1. Analiza porównawcza stanu początkowego i końcowego

Analogicznie jak w przypadku omawianego wcześniej algorytmu genetycznego, punktem odniesienia dla oceny wydajności algorytmu mrówkowego jest najlepsza trasa w generowana w sposób całkowicie losowy.


- **Koszt startowy (najlepszy z losowej populacji):** 237 209,39 m
- **Najlepszy koszt ACO (końcowy):** 115 985,84 m
- **Liczba wykonanych cykli:** 200 (osiągnięto narzucony limit iteracji)

Dzięki zastosowaniu algorytmu osiąga się redukcję dystansu o **121 223,55 m**, co oznacza poprawę o **51.10%** względem najlepszej trasy losowej. Dowodzi to wysokiej skuteczności zaimplementowanego algorytmu. System zdołał odrzucić nieefektywne ścieżki, wzmacniając najbardziej optymalną. Warto zauważyć, że wynik ten jest zbliżony do wyniku osiągniętego przez algorytm genetyczny (poprawa ok. 114 km).

Istotnym wnioskiem analitycznym jest brak pełnej zbieżności populacji w momencie osiągnięcia limitu 200 cykli. Oznacza to, że pomimo uzyskania rozwiązania o bardzo dobrej jakości, mrówki nadal eksplorowały przestrzeń rozwiązań w poszukiwaniu alternatywnych ścieżek. Co prawda poza czasem obliczeń nic nie stoi na przeszkodzie, aby pozwolić algorytmowi kontynuować poszukiwania jeszcze lepszego rozwiązania, jednak wyniki przeprowadzonej optymalizacji metodą mesh grid jednoznacznie wskazały zasadność ograniczenia liczby iteracji do 200. Prawdopodobnie dalsze przeszukiwanie przestrzeni rozwiązań mogłoby doprowadzić do niewielkiej poprawy długości trasy, jednak uzyskany rezultat przy przyjętych parametrach jest na tyle satysfakcjonujący, że nie uzasadnia dalszej eksploracji. Zaobserwowana dynamika procesu wskazuje, że mechanizmy ewaporacji i wzmocnienia feromonowego pozostawały w równowadze do końca działania algorytmu, zapobiegając przedwczesnej stagnacji populacji. W rezultacie mrówki kontynuowały eksplorację przestrzeni rozwiązań, weryfikując opłacalność sąsiednich krawędzi grafu aż do momentu osiągnięcia zdefiniowanego kryterium zatrzymania.

5.3.2. Proces formowania trasy

W celu dogłębnego zrozumienia dynamiki działania zaimplementowanej metaheurystyki, proces samoorganizacji roju został poddany analizie wizualnej. Obserwacja zmian w rozkładzie wirtualnego feromonu na mapie aglomeracji pozwala zweryfikować poprawność matematycznego modelu systemu. Analizę rozpoczyna ocena stanu zerowego, obrazującego surową przestrzeń poszukiwań.




Rysunek 13. Stan początkowy algorytmu mrówkowego.

Mapa przedstawiona na rys. 13 prezentuje punkt wyjścia dla procesu optymalizacji z wykorzystaniem algorytmu mrówkowego. Można zauważyć, jak dużą złożonością charakteryzuje się nieoptymalizowana sieć drogowa Krakowa, z którą musi zmierzyć się algorytm. Widoczna gęsta, chaotyczna sieć niebieskich połączeń reprezentuje praktycznie każdą możliwą ścieżkę o zróżnicowanej intensywności w zadanym grafie asymetrycznym.

Zgodnie z parametrami opisanymi w sekcji 5.2.1, w cyklu zerowym macierz feromonów τ jest inicjalizowana wartością stałą, co skutkuje zjawiskami widocznymi na mapie, takimi jak brak znaczącej preferencji określonych tras, wynikający z identycznego poziomu feromonu na wszystkich krawędziach grafu. Prowadzi to do wysokiego kosztu początkowego, ponieważ efektem działania algorytmu są w tym etapie nieefektywne, krzyżujące się oraz powracające trajektorie, generujące koszt początkowy na poziomie około 237 kilometrów.

Warto podkreślić, że decyzje podejmowane w pierwszej iteracji są oparte wyłącznie na informacji heurystycznej η , czyli fizycznej bliskości kolejnego punktu dostawy, oraz na mechanizmie losowego wyboru (tzw. ruletce probabilistycznej). Wizualizacja tego stanu jest niezbędna do zrozumienia, w jaki sposób algorytm w kolejnych iteracjach zaczyna preferować bardziej efektywne rozwiązania, stopniowo eliminując te mniej korzystne.



Isotopie role w analizie odgrywa autorski moduł wizualizacji (`plot_100_states`), który został na-

Declaration of interest: The authors have nothing to disclose.


Zwieńczeniem procesu optymalizacji jest wyłonienie oficjalnego ostatecznego przebiegu trasy, reprezentującej najlepsze wyniki uzyskany przez stado w trakcie wszystkich iteracji.



Rysunek 15. Ostateczny wynik optymalizacji algorytmem mrówkowym.

Rysunek 15 prezentuje finalny rezultat działania inteligencji grupowej, osiągający całkowity koszt na poziomie 115,99 km. Wyznaczona trasa charakteryzuje się wysoką spójnością oraz doskonałą logiką przestrzenną. Widoczne jest, że algorytm mrówkowy z powodzeniem wyeliminował wszelkie zbędne manewry. Wypracowany przebieg dostaw jest wysoce intuicyjny, naturalnie łącząc sąsiadujące ze sobą automaty paczkowe w lokalne klastry i bezbłędnie respektując przy tym uwarunkowania fizycznej sieci drogowej (w tym ulice jednokierunkowe). Udowadnia to, że zastosowany mechanizm sprzężenia zwrotnego, oparty na odkładaniu wirtualnej substancji zapachowej, skutecznie poprowadził populację do wysoce satysfakcjonującego rozwiązania, które swoją jakością i realną przydatnością logistyczną niemal idealnie dorównuje wynikom osiągniętym wcześniej za pomocą algorytmu genetycznego.

5.3.3. Dynamika procesu optymalizacji i zbieżności populacji



Rysunek 16. Przebieg procesu optymalizacji w algorytmie mrówkowym (ACO) na przestrzeni 200 iteracji.

Wykres zbieżności (Rys. 16) dostarcza informacji na temat balansu pomiędzy dwoma głównymi siłami w algorytmach rojowych: eksploatacją (wykorzystywaniem znanych, dobrych ścieżek) a eksploracją (poszukiwaniem nowych, potencjalnie lepszych rozwiązań). Analiza przebiegu krzywych pozwala wyróżnić dwie odmienne fazy działania zaimplementowanego systemu.

W początkowej fazie działania algorytmu (iteracje 0-25) obserwujemy drastyczny, niemal wykładniczy spadek wartości funkcji kosztu dla wszystkich trzech wskaźników. Średni koszt trasy maleje z ponad 200 km do poziomu około 140 km w zaledwie kilkanaście cykli. Jest to moment, w którym stado błyskawicznie eliminuje najdłuższe, całkowicie losowe ścieżki i zaczyna koncentrować feromon na głównych korytarzach komunikacyjnych.

Po 25. iteracji algorytm wchodzi w stan pozornej stabilizacji, jednakże krzywe nigdy nie ulegają całkowitemu spłaszczeniu, a odległość między najgorszym a najlepszym osobnikiem pozostaje wyraźna. Ciągłe, oscylacyjne wahania kosztu najlepszej trasy (niebieska linia) wokół poziomu 120-130 km wynikają z założeń zaimplementowanego modelu stochastycznego.

Zjawisko to jest bezpośrednim efektem współczynnika ewaporacji ustawionego na poziomie 0.5 oraz probabilistycznego charakteru wyboru węzłów (ruletka decyzyjna). Pojedyncze mrówki, nawet w późnych iteracjach, podejmują ryzyko wyboru gorszych tras. Większość z tych prób kończy się fiaskiem (co odzwierciedlają widoczne skoki zielonej krzywej najgorszego kosztu), jednak niektóre z nich pozwalają na odkrycie nowych, minimalnie krótszych wariantów objazdów. To właśnie te nieustanne fluktuacje i odporność roju na całkowitą stagnację doprowadziły ostatecznie do wyłonienia trasy o długości 115,99 km.

5.4. Podsmowanie procesu optymalizacji mrówkowej

Przeprowadzona implementacja i analiza działania algorytmu mrówkowego w problemie optymalizacji tras kurierskich pozwoliła na sformułowanie jednoznacznych wniosków dotyczących efektywności tej metody.

5.4.1. Kluczowe osiągnięcia i metryki

Przeprowadzona implementacja i analiza algorytmu mrówkowego (ACO) dowiodła wysokiej skuteczności metod opartych na inteligencji stadnej w rozwiązywaniu złożonych problemów logistycznych. System w ciągu 200 iteracji zredukował początkowy koszt trasy o ponad 51% (z 237 km do ok. 116 km), generując spójny i zoptymalizowany cykl dostaw, który w pełni respektuje uwarunkowania i asymetrię miejskiej sieci drogowej.

5.4.2. Interpretacja zachowania roju i jakości wyniku

Najważniejszym wnioskiem płynącym z przeprowadzonych badań jest fakt, że przedstawiona implementacja mechanizmów ewaporacji i depozycji feromonu pozwoliła skutecznie zbalansować procesy eksploatacji i eksploracji. Algorytm uniknął zjawiska przedwczesnej zbieżności, zachowując zdolność do przeszukiwania grafu aż do ostatniego cyklu. Uzyskany rezultat jest wysoce satysfakcjonujący i stanowi solidną, biologiczną alternatywę dla modelu genetycznego.

5.4.3. Materiały uzupełniające i załączniki

W celu pełniejszego zobrazowania wyników i dynamiki pracy roju, do niniejszego opracowania dołączono cyfrowe materiały uzupełniające:

Interaktywna mapa (HTML): Pozwala na szczegółowe, płynne przybliżanie i śledzenie ostatecznej trasy w odniesieniu do rzeczywistej topografii miasta i poszczególnych ulic.

Animacja (GIF): Wizualizuje proces samoorganizacji stada „cykl po cyklu”, obrazując stopniowe wygasanie suboptymalnych ścieżek i krystalizację głównego korytarza feromonowego.

PORÓWNANIE ALGORYTMU EWOLUCYJNEGO I MRÓWKOWEGO

Niniejszy rozdział stanowi bezpośrednie zestawienie wyników uzyskanych przez dwie zaimplementowane metaheurystyki: model ewolucyjny (algorytm genetyczny - GA) oraz model inteligencji stadnej (algorytm mrówkowy - ACO). Oba algorytmy zostały przetestowane na identycznej instancji Asymetrycznego Problemu Komiwożera, wykorzystującej tę samą macierz kosztów opartą na rzeczywistej topologii drogowej Krakowa. Celem porównania jest ocena skuteczności obu metod względem siebie oraz względem rozwiązania w pełni losowego.


6.1.Zestawienie danych liczbowych

W tabeli poniżej zagregowano ostateczne metryki opisujące jakość wygenerowanych tras. Za punkt odniesienia (wartość bazową) przyjęto najlepszego osobnika z początkowej, losowo wygenerowanej populacji.

Tabela 1. Porównanie kosztów tras dla analizowanych wariantów względem trasy losowej

Wariant	Koszt [m]	Koszt [km]	Poprawa [m]	Poprawa [%]
Losowa startowa	237209.39	237.21	—	—
Algorytm genetyczny	114015.60	114.02	123193.79	51.93
Algorytm mrówkowy	115985.84	115.99	121223.55	51.10

Graficznym dopełnieniem powyższych danych liczbowych jest wykres porównawczy, pozwalający na ocenie zbieżność wyników obu metaheurystyk oraz ich przewagę nad brakiem optymalizacji



Rysunek 17. Graficzne zestawienie całkowitego kosztu tras (w kilometrach) dla rozwiązania losowego oraz wyników optymalizacji metaheurystycznej (GA i ACO).

Wizualizacja danych na wykresie słupkowym (Rys. 17) oraz analiza wartości stabelaryzowanych pozwala na wyciągnięcie kilku istotnych wniosków o charakterze inżynierskim.


Przede wszystkim, obie zastosowane metody optymalizacji wykazały się znakomitą i wysoce powtarzalną skutecznością. Zarówno podejście ewolucyjne, jak i rojowe pozwoliło na zredukowanie dystansu o ponad połowę (odpowiednio 51,93% oraz 51,10%) względem trasy wyznaczonej w sposób losowy. Oznacza to oszczędność rzędu 120 kilometrów na pojedynczym cyklu dostaw, co w realiach logistyki miejskiej przekłada się na drastyczne obniżenie kosztów paliwa, amortyzacji floty oraz czasu pracy kuriera.

Bezpośrednie starcie obu metaheurystyk kończy się minimalnym zwycięstwem algorytmu genetycznego, który wygenerował trasę krótszą o dokładnie 1970,24 m w stosunku do algorytmu mrówkowego. Z perspektywy matematycznej GA okazał się skuteczniejszy, jednak oceniając ten wynik w kontekście skali całego problemu (trasa licząca ponad 114 km), różnica rzędu niespełna 2 kilometrów (ok. 1,7% całkowitego dystansu) jest wartością marginalną.

Można zatem stwierdzić, że oba algorytmy zbiegły do bardzo silnych minimów lokalnych o zbliżonej jakości (lub do samego optimum globalnego). Różnica 1,97 km może wynikać z subtelnych różnic w doborze hiperparametrów (np. limitu stagnacji w GA vs 200 twardych cykli w ACO) lub po prostu ze stochastycznej natury obu metod. Obie implementacje należy uznać za w pełni poprawne i gotowe do zastosowania w realnych systemach planowania tras.

6.2. Analiza rozkładu dystansów lokalnych

W celu pogłębienia wiedzy na temat zróżnicowania mechanik optymalizacyjnych obu algorytmów, przeprowadzona została analiza statystyczna długości pojedynczych przejazdów, rozumianych jako odcinki pomiędzy kolejnymi paczkomatami na trasie. Zestawienie to przedstawia rys. 18, które obrazuje w jaki sposób udało się zredukować koszt operacyjny.




Rysunek 18. Analiza statystyczna rozkładu długości pojedynczych przejazdów w wygenerowanych trasach.

Przyglądając się benchmarkowej próbie losowej można dostrzec, charakterystyczny dla braku optymalizacji, szeroki rozrzut danych. Jak widać na boxplocie mediana oscyluje około aż 7 kilometrów, a rozstęp międzykwartylowy jest bardzo szeroki. Krzywa gęstości jest widocznie, znacznie bardziej przesunięta w stronę wyższych wartości niż pozostałe 2 wykresy oraz jako jedyny jest zbliżony kształtem do rozkładu normalnego.

Oba zaimplementowane algorytmy dokonały radykalnej zmiany w strukturze dystansów. Jak można zauważyć na obu wykresach, rozkłady uległy wyraźnemu zawężeniu, a same wartości znacznie zmalały (mediana ok. 2km). Świadczy to o tym, że algorytmy znacząco poprawiły właściwości statystyczne tras. Dodatkowo krzywe gęstości dla obu algorytmów są do siebie bardzo zbliżone, co dowodzi że oba zbliżały się do bardzo podobnego, wysoko zoptymalizowanego rozwiązania.

6.3. Wizualne porównanie tras na mapie

Uzupełnieniem analizy liczbowej jest bezpośrednie nałożenie wyników obu algorytmów na rzeczywistą mapę drogową aglomeracji krakowskiej (Rys. 19). Taka wizualizacja pozwala na weryfikację logiki przestrzennej, jaką kierowały się zaimplementowane systemy sztucznej inteligencji.



Rysunek 19. Wizualne zestawienie najlepszych tras wygenerowanych przez algorytm genetyczny (linia zielona) oraz algorytm mrówkowy (linia fioletowa).

Najważniejszym i najbardziej rzucającym się w oczy wnioskiem płynącym z analizy mapy jest niemal całkowite pokrywanie się obu wygenerowanych tras. Pomimo zastosowania dwóch znacząco różniących się paradygmatów, oba algorytmy niezależnie od siebie wypracowały niemalże identyczny przebieg dostaw. Trasa jest realizowana przez genetyka i mrówki w dokładnie ten sam, wysoce zoptymalizowany sposób. Stanowi to ostateczny dowód na to, że oba systemy skutecznie odnalazły globalne optimum (lub jego bezpośrednie sąsiedztwo) dla rozpatrywanego problemu logistycznego.

Zarejestrowana wcześniej różnica w dystansie rzędu 1,97 km wynika z subtelnych rozbieżności, widocznych na mapie w postaci delikatnych odgałęzień (rozwarstwień zielonej i fioletowej linii) w centralno-zachodniej części miasta oraz w bezpośrednim sąsiedztwie sortowni. Warto zauważyć że zjawisko obserwowane w gęstej sieci miejskiej, gdzie niewielka zmiana kolejności obsługi 2-3 lokalnych paczkomatów może wymusić inny przejazd drogami jednokierunkowymi, co znacząco wpływa na końcowy dystans. Ostatecznie, obie trasy cechują się doskonałą spójnością przestrzenną, brakiem zbędnych przecięć i pełną legalnością w świetle przepisów ruchu drogowego.

PODSUMOWANIE I WNIOSKI KOŃCOWE

Głównym celem niniejszego projektu było zaprojektowanie, zaimplementowanie oraz dogłębna analiza skuteczności dwóch wiodących metaheurystyk sztucznej inteligencji - Algorytmu Genetycznego oraz Algorytmu Mrówkowego - w kontekście optymalizacji miejskich tras kurierskich. Badania przeprowadzono na bazie rzeczywistej topologii drogowej Krakowa, rozwiązując Asymetryczny Problem Komiwojażera, w którym uwzględniono m.in. skomplikowany układ dróg jednokierunkowych.

Przeprowadzone eksperymenty oraz analiza zebranych danych pozwalają na sformułowanie następujących wniosków końcowych:

- **Wysoka skuteczność optymalizacyjna:** Obie zbadane metody udowodniły swoją ogromną przydatność w rozwiązywaniu złożonych problemów klasy NP-trudnych. Zarówno podejście ewolucyjne, jak i rojowe pozwoliło na redukcję początkowego, losowego kosztu trasy o ponad **51%** (z 237,21 km do poziomu ok. 114-116 km). Wygenerowane ścieżki cechowały się logiką przestrzenną, brakiem pętli i pełną zgodnością z przepisami ruchu drogowego.
- **Zderzenie paradygmatów (GA vs ACO):** W bezpośrednim starciu minimalną przewagę uzyskał algorytm genetyczny, generując trasę o niespełna 2 kilometry krótszą od rozwiązania mrówkowego. Wynika to z agresywnego mechanizmu selekcji oraz skuteczności inwersji i krzyżowania, które potrafiły precyzyjniej wygładzić mikro-anomalie na trasie. Algorytm mrówkowy wykazał się z kolei nieco większą dynamiką eksploracji pod koniec swojego działania (dzięki procesowi parowania), co czyni go bardziej odpornym na przedwczesną zbieżność. Należy jednak zaznaczyć, że przewaga algorytmu genetycznego nad mrówkowym wynika jedynie z dobranych parametrów (czasie optymalizacji były takie momenty że algorytm mrówkowy dawał znacznie lepsze wyniki od GA).
- **Odporność na asymetrię przestrzeni:** Wykorzystanie biblioteki OSMnx do pobrania grafów typu *drive* i wygenerowanie asymetrycznej macierzy kosztów było kluczowym krokiem projektowym. Pokazało to, że obie metaheurystyki (odpowiednio poprzez funkcję fitness oraz heurystykę lokalną) potrafią bezbłędnie karać osobniki próbujące poruszać się pod prąd i samoczynnie formować poprawne, cykle logistyczne.

Podsumowując, można przyjąć że projekt zakończył się pełnym sukcesem. Implementacja algorytmów inspirowanych naturą pozwoliła na wyłonienie rozwiązań, które z powodzeniem realizują założenia logistyczne, łącząc optymalizację kosztów operacyjnych z wysoką elegancją matematyczną samej sztucznej inteligencji

LITERATURA

- Flasiński, M. (2018). Obliczenia ewolucyjne. In *Wstęp do sztucznej inteligencji*, pages 58–73. Wydawnictwo Naukowe PWN, Warszawa.
- Prof. dr hab. inż. Norbert Skoczylas (2026a). Inteligencja obliczeniowa w analizie danych. Treść wykładu Metody ewolucyjne/Algorytmu genetyczne. Wydział Geologii, Geofizyki i Ochrony Środowiska, AGH, Kraków.
- Prof. dr hab. inż. Norbert Skoczylas (2026b). Inteligencja obliczeniowa w analizie danych. Treść wykładu Inne algorytmy optymalizacyjne inspirowane przyrodą. Wydział Geologii, Geofizyki i Ochrony Środowiska, AGH, Kraków.
- Ziółkowski, J., Miziołek, A., and Ćwik, D. (2018). Problem komiwojażera – studium przypadku. *Systemy Logistyczne Wojsk*, 49(2):236–245.